UNIVERSITÉ PARIS 8 DES CRÉATIONS

Master Informatique - Ingénierie en IA (M2)

Module : IA générative — Agents et RAG

Rapport de TP n°3 :

Construire un Agentic RAG sur la jurisprudence de la Cour de cassation

---

Étudiants :
Anas EL ALAOUI
Assala AMRANI

Encadrant :
M. Salah BOUCHAMA

Date : 2 Novembre 2026

Année Universitaire 2026 – 2027

Table des matières

1 Objectif et démarche **2**

2 Point de départ : le RAG du TP2 **2**

3 Architecture agentique **3**

3.1 État partagé 4

3.2 Outils 4

3.3 Décision de l'agent et garde-fous 4

3.4 Vérification avant la réponse finale 5

3.5 Interface et exécution 5

3.6 Bonus réalisés 6

4 Tests des trois scénarios **7**

4.1 Scénario 1 — RAG simple 7

4.2 Scénario 2 — Recherche multi-étapes 8

4.3 Scénario 3 — Information insuffisante 9

5 Comparaison avec le RAG statique du TP2 **11**

6 Analyse **12**

6.1 Ce qui fonctionne 12

6.2 Échecs observés 12

6.3 Améliorations possibles 13

7 Conclusion **13**

A Installation et reproduction des résultats **14**

A.1 Prérequis 14

A.2 Installation et lancement 14

A.3 Reproduire les expériences de ce rapport 14

A.4 Organisation du code 14

B Glossaire **15**

Guide de lecture. La section 1 pose l'objectif et la démarche ; la section 2 rappelle le RAG du TP2, réutilisé comme outil. La section 3 décrit l'architecture de l'agent (graphe, état, outils, garde-fous, vérification, interface). La section 4 présente les traces réelles des trois scénarios demandés, la section 5 les compare au RAG statique, et la section 6 analyse ce qui fonctionne, les échecs observés et les améliorations possibles. Les annexes expliquent comment reproduire les résultats et définissent les termes techniques.

1 Objectif et démarche

Corpus	1 973 décisions de la Cour de cassation (2015–2025, publiées au Bulletin), 26 568 passages
Index	hybride BM25 + embeddings `multilingual-e5-small`, fusion RRF
LLM	`llama3.2:3b` servi par Ollama, en local sur CPU
Agent	LangGraph : agent → outils → réponse → vérificateur, 5 étapes max
Outils	`search_cases`, `read_case`, `external_search` (Wikipédia FR)
Interface	application web locale, trace en direct (SSE), sources corpus / externes séparées

Le TP2 a produit un RAG *statique* : pour chaque question, la même chaîne s'exécute (une recherche, des passages, une génération). Le TP3 transforme ce système en **agent** : le modèle choisit l'action suivante (chercher, lire une affaire, consulter une source externe, répondre), le code exécute l'outil, l'observation revient dans l'état, et un **vérificateur** décide si les preuves suffisent avant de laisser passer la réponse.

Trois principes ont guidé la conception :

1. **Réutiliser le TP2 tel quel comme outil.** Le corpus, l'index et la recherche ne changent pas : l'agent les appelle à travers `search_cases` et `read_case`.
2. **Contrôler un petit modèle par le code.** Un modèle de 3 B paramètres sur CPU fait des choix maladroits ; des *garde-fous* explicites, visibles dans la trace, corrigent les décisions invalides au lieu de les cacher.
3. **Tout rendre observable.** Chaque décision, appel d'outil, observation et vérification est publiée en direct dans l'interface et sauvegardée (JSON + Markdown).

2 Point de départ : le RAG du TP2

Données. Le fichier `cour_de_cassation.jsonl.gz` du dataset `antoinejeannot/jurisprudence` (environ 1 Go, 553 000 décisions) est lu en flux, sans être stocké. On garde les décisions rendues depuis 2015, **publiées au Bulletin** (celles qui font jurisprudence) et disposant d'un découpage en zones, puis on tire un échantillon équilibré par chambre (tirage par réservoir) : 1 973 décisions distinctes, dont 94 % ont un *sommaire* officiel.

Découpage. Le dataset indique pour chaque décision la position des zones *introduction, exposé du litige, moyens, motivations, dispositif*. Le découpage suit ces zones (fenêtres de 170 mots, recouvrement de 35 mots) : un passage garde ainsi son *rôle juridique*, ce qui sera essentiel pour l'agent. Le sommaire et les thèmes forment un passage à part, souvent le meilleur point d'entrée pour une recherche par notion.

Index hybride. BM25 (tokenisation française, mots vides, racinisation Snowball) capte les termes exacts du droit et les numéros d'articles ; les embeddings `multilingual-e5-small` capturent les reformulations en langage naturel. Les deux classements sont fusionnés par *Reciprocal Rank Fusion* ($k = 60$), insensible aux échelles de score. Un numéro de pourvoi (`23-20.161`) donne un accès direct à la décision.

Résumé et questions-réponses. Le résumé suit la grille du juriste (faits, procédure, question de droit, décision, portée) ; la question-réponse travaille sur les passages de l'affaire sélectionnée. Dans les deux cas le modèle doit citer ses sources `[P`n`]`, en JSON, et le code vérifie que chaque citation renvoie à un passage réellement fourni.

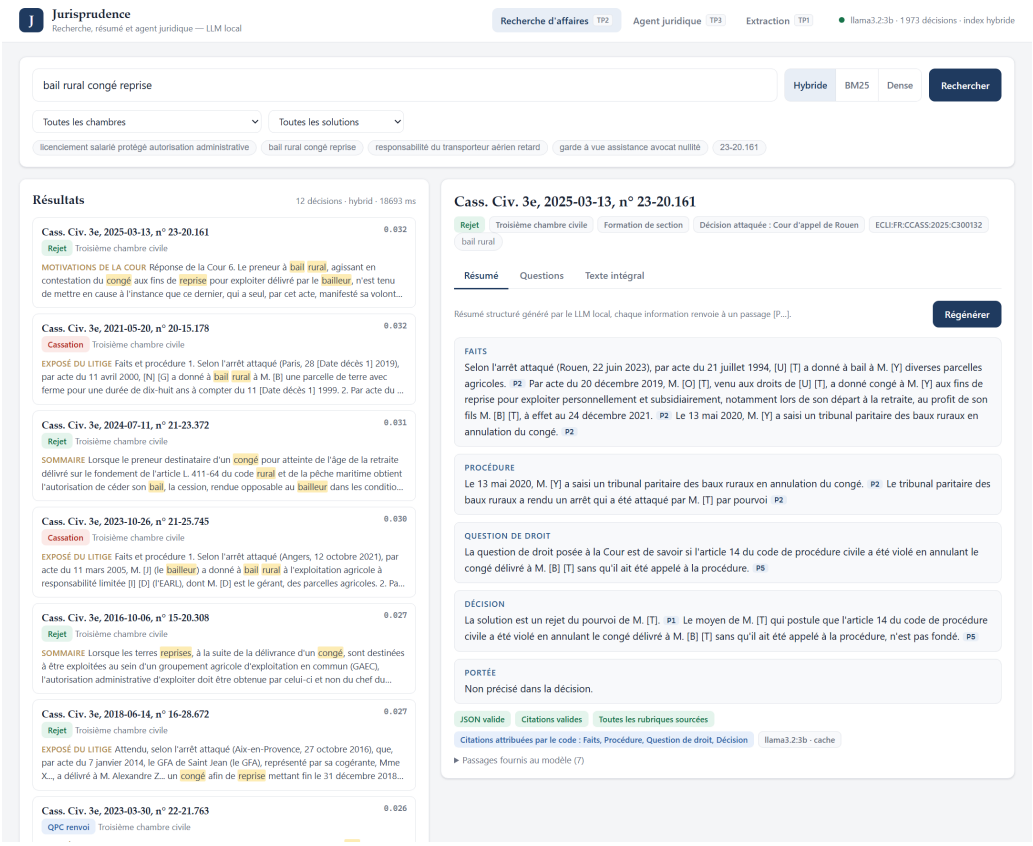


Figure 1 – Interface du TP2 : recherche hybride, résultats avec le passage le plus pertinent, fiche de l'affaire et résumé structuré sourcé.

3 Architecture agentique

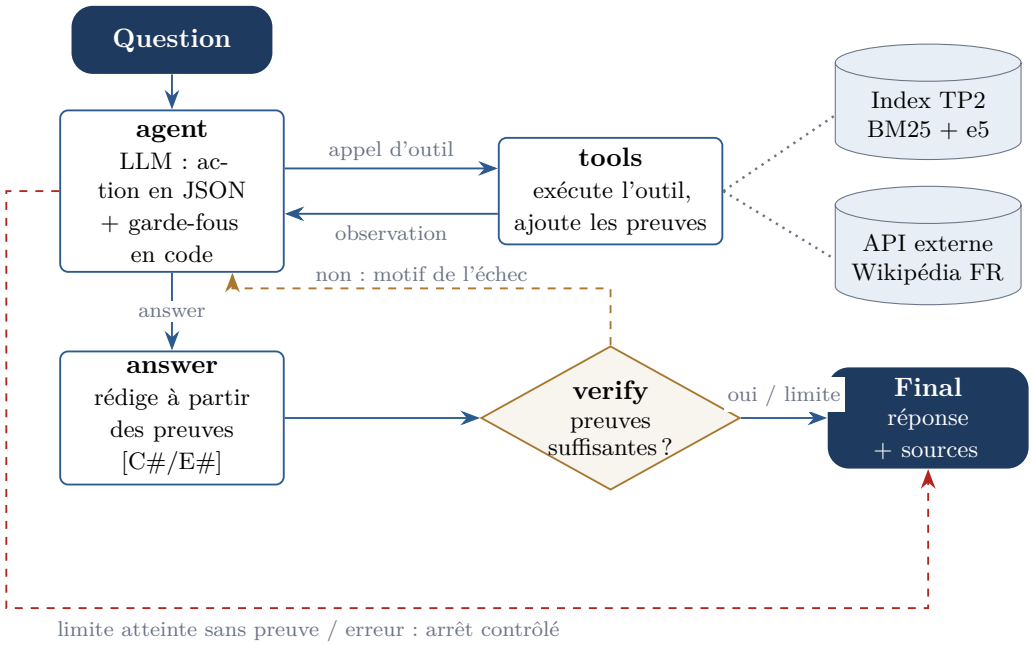


Figure 2 – Graphe LangGraph de l'agent. Les flèches pleines sont le chemin nominal ; le vérificateur renvoie vers l'agent avec le motif de l'échec tant que la limite d'étapes n'est pas atteinte.

3.1 État partagé

L'état (`AgentState`) ne contient que ce qui sert à décider :

Champ	Contenu
`question`, `memory`	question courante ; affaire et échange précédents (bonus mémoire)
`evidence`	preuves citables numérotées : `C1, C2…` (corpus), `E1…` (externe)
`candidates`	décisions trouvées, étiquetées `D1, D2…` (l'agent manipule ces étiquettes courtes plutôt que des identifiants longs)
`searches`, `read_cases`	historique des recherches et des affaires lues (détection des répétitions)
`iteration`, `max_iterations`	compteur de décisions et limite (5 par défaut)
`feedback`, `verification`	motif du dernier échec de vérification, détail des contrôles
`draft`, `final`, `status`	brouillon, réponse finale avec sources, statut (vérifiée, non vérifiée, arrêt, erreur)

La trace, les compteurs (appels LLM, tokens, latence) et la validation humaine vivent dans un `RunContext` transmis par la configuration du graphe : ils observent l'exécution sans polluer l'état métier.

3.2 Outils

Outil	Comportement
`search_cases(query, k)`	recherche hybride du TP2, regroupée par décision ; renvoie titre, solution et extrait. Les trois premiers résultats fournissent déjà une preuve citable (souvent le sommaire).
`read_case(case_id)`	lecture « juridique » : sommaire officiel + le passage le plus proche de la question dans chacune des zones *exposé, moyens, motivations, dispositif*. La question est enrichie du vocabulaire des arrêts (« fait grief », « rejette »…).
`external_search(query)`	API MediaWiki de Wikipédia FR (recherche + résumé introductif). Les résultats sont marqués **externes** et ne peuvent jamais être présentés comme de la jurisprudence.

Une erreur d'outil (`ToolError` : décision introuvable, API indisponible, requête vide) est affichée dans la trace en rouge, enregistrée dans l'état, et l'agent continue ; une erreur du LLM provoque un arrêt contrôlé.

3.3 Décision de l'agent et garde-fous

À chaque tour, le LLM reçoit un état résumé (question, recherches faites, décisions trouvées avec leurs étiquettes, affaires déjà lues, nombre de preuves, retour du vérificateur, étape $i/5$) et répond en JSON : `{"reason", "action", "args"}`. La justification est une phrase courte : la trace est *opérationnelle*, pas un long raisonnement interne.

Le modèle 3 B se trompe de façon prévisible ; le code applique alors des garde-fous, chacun affiché dans la trace :

- action inconnue → recherche (ou réponse si des preuves existent) ;
- réponse demandée sans aucune preuve → recherche ;
- recherche identique à une précédente → réponse si une affaire a été lue, sinon lecture du meilleur candidat, sinon source externe, sinon arrêt ;
- affaire déjà lue → réponse (ou nouvelle affaire si le vérificateur a demandé plus de preuves) ;
- numéro de pourvoi cité dans la question et décision trouvée mais non lue → lecture obligatoire ;

— nouvelle réponse après un refus du vérificateur sans nouvelle preuve → nouvelle action de recherche.

3.4 Vérification avant la réponse finale

Le nœud `verify` applique des contrôles déterministes puis un juge LLM :

Contrôle	Règle
Preuves présentes	au moins un passage du corpus dans l'état
Citations valides	la réponse cite au moins une preuve, et uniquement des preuves existantes
Décision du corpus citée	une réponse appuyée seulement sur Wikipédia est refusée
Affaire demandée citée	si la question vise un numéro de pourvoi, les passages cités viennent de cette affaire
Notions clés sourcées	un terme rare de la question (IDF ≥ 6, ex. « imprévision ») repris dans la réponse doit figurer dans les preuves
Pas d'information non sourcée	chaque phrase partage au moins 40 % de ses mots (racinisés) avec les preuves fournies
Cohérence réponse / passages	juge LLM (« chaque affirmation est-elle justifiée par les passages ? ») ; une objection n'est retenue que si l'affirmation est réellement peu présente dans les preuves

En cas d'échec, le motif (« la réponse s'appuie sur une autre affaire », « phrase non soutenue », « manque : … ») devient le `feedback` de l'agent, qui doit relancer une recherche, reformuler ou lire une autre affaire. À la limite d'étapes, la réponse est rendue avec le statut *non vérifiée* et un avertissement visible.

3.5 Interface et exécution

Le run tourne dans un thread côté serveur (`graph.stream(..., stream_mode="updates")`) ; chaque nœud publie ses événements dans une file, diffusée au navigateur en *Server-Sent Events*. L'utilisateur voit en direct le nœud actif du graphe, l'outil appelé avec ses arguments, le résumé de l'observation, le résultat de la vérification et la condition d'arrêt. La réponse finale sépare les **sources du corpus** et les **sources externes** ; les citations sont cliquables.

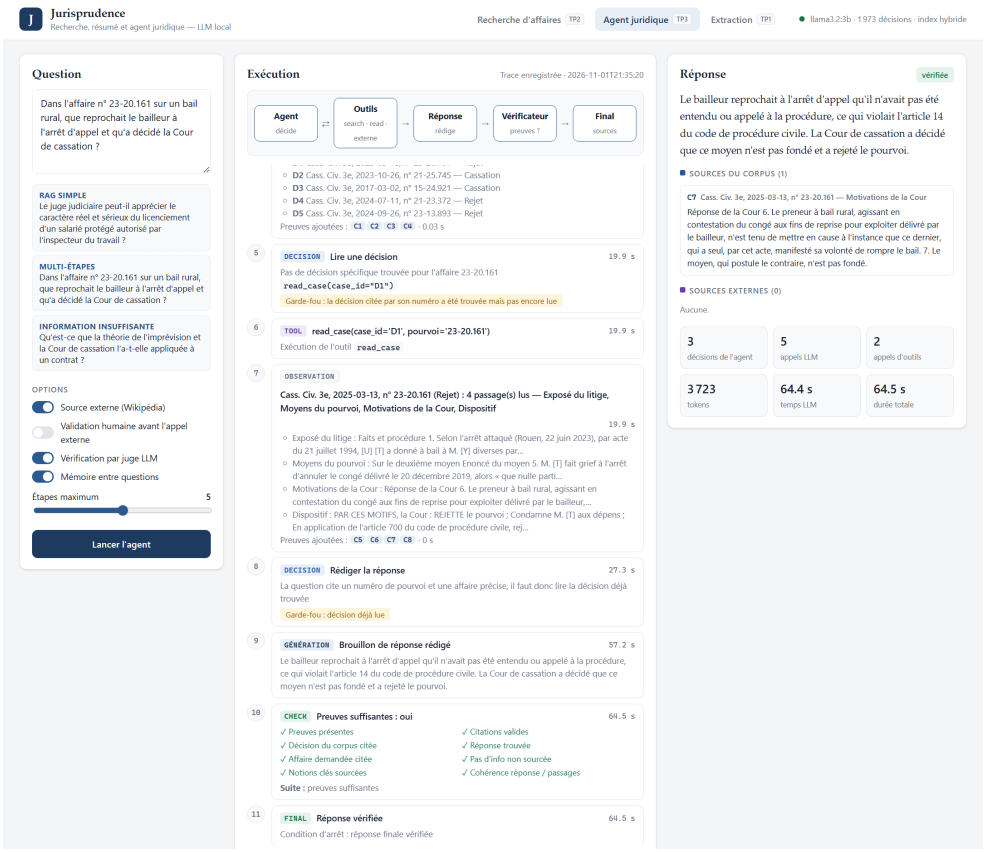


Figure 3 – Onglet « Agent juridique » : options (source externe, validation humaine, juge LLM, mémoire, limite d'étapes), graphe avec le nœud actif, trace étape par étape et réponse avec ses sources et ses mesures.

3.6 Bonus réalisés

— **Mémoire** : l'affaire citée dans la réponse précédente est proposée à l'agent sous l'étiquette `D0` (question de suivi : « et quelle a été la solution ? »).

— **Human-in-the-loop** : option de validation avant tout appel externe ; un refus est enregistré et l'agent continue sans la source externe.

— **Observabilité** : appels LLM, tokens, temps passé dans le modèle et durée totale, par run et par appel.

— **Rôles séparés** : le rédacteur et le vérificateur sont deux nœuds distincts avec des consignes différentes ; le superviseur (le graphe) décide quand appeler l'un ou l'autre.

4 Tests des trois scénarios

Les traces ci-dessous sont générées automatiquement à partir des exécutions réelles (`python -m scripts.run_scenarios`, fichiers dans `docs/traces/`). Les temps sont mesurés sur CPU, sans GPU.

4.1 Scénario 1 — RAG simple

Question : Le juge judiciaire peut-il apprécier le caractère réel et sérieux du licenciement d'un salarié protégé autorisé par l'inspecteur du travail ? Une seule recherche doit suffire : le sommaire officiel d'un arrêt de la chambre sociale énonce la règle. On vérifie que l'agent ne multiplie pas les étapes.

#	t (s)	Type	Détail
1	0.0	DÉBUT	Question reçue ; 5 étapes max, source externe activée
2	11.0	DECISION	**Rechercher dans le corpus** — Aucune preuve n'a été trouvée, il faut donc commencer par une recherche plus large `search_cases("query": "licenciement salarié protgé inspecteur du travail", "k": 5)`
3	11.0	TOOL	`search_cases(query='licenciement salarié protgé inspecteur du travail', k=5)`
4	28.9	OBSERVATION	5 décision(s) trouvée(s) ; meilleure : Cass. Soc., 2018-09-12, n° 16-26.853 ; preuves ajoutées : C1, C2, C3, C4, C5
5	47.1	DECISION	**Rédiger la réponse** — Pas de décision spécifique sur le caractère réel et sérieux du licenciement d'un salarié protégé *garde-fou : des preuves existent déjà : le vérificateur jugera si elles suffisent*
6	58.6	GÉNÉRATION	Brouillon citant C1, C2, C3, C4, C5 : *Non, le juge judiciaire ne peut pas apprécier le caractère réel et sérieux du licenciement d'un salarié protégé autorisé par l'inspecteur du travail*
7	85.2	CHECK	**Preuves suffisantes : oui** ; suite : preuves suffisantes
8	85.2	FINAL	**Réponse vérifiée** — condition d'arrêt : réponse finale vérifiée

Réponse finale (vérifiée)

Non, le juge judiciaire ne peut pas apprécier le caractère réel et sérieux du licenciement d'un salarié protégé autorisé par l'inspecteur du travail

[C1] Corpus — Cass. Soc., 2018-09-12, n° 16-26.853 (Moyens du pourvoi) : *« tribunal du commerce, en ce qui concerne les capitaines ayant le commandement du navire" ; que s'il instaure une procédure de conciliation obligatoire et préalable à… »*

[C2] Corpus — Cass. Soc., 2018-09-12, n° 16-26.853 (Sommaire) : *« Aux termes de l'article 28 de la convention collective du 14 mai 1959 applicable aux officiers des entreprises de navigation du territoire de la Polynésie française… »*

[C3] Corpus — Cass. Soc., 2024-12-11, n° 23-10.439 (Motivations de la Cour) : *« le ministre compétent annule, sur recours hiérarchique, la décision de l'inspecteur du travail autorisant le licenciement d'un salarié investi de l'un des mandats… »*

[C4] Corpus — Cass. Soc., 2024-12-11, n° 23-10.439 (Sommaire) : *« Il résulte des articles L. 2422-1 et L. 2422-4 du code du travail que seule la demande de réintégration doit être formée, à peine d'irrecevabilité, dans le délai de… »*

[C5] Corpus — Cass. Soc., 2020-11-04, n° 19-11.865 (Motivations de la Cour) : *« que le salarié avait, le 13 décembre 2014, informé son employeur de son élection aux fonctions d'adjoint délégué au sport de la commune de Bouguenais le 20 novembre… »*

Mesures : 2 décisions de l'agent, 4 appels LLM, 1 appels d'outils, 4898 tokens, 85.2 s. Chemin : agent → tools → agent → answer → verify → final.

4.2 Scénario 2 — Recherche multi-étapes

Question : Dans l'affaire n° 23-20.161 sur un bail rural, que reprochait le bailleur à l'arrêt d'appel et qu'a décidé la Cour de cassation ? Il faut trouver la décision puis lire précisément le moyen (« fait grief à l'arrêt… ») et la réponse de la Cour.

#	t (s)	Type	Détail
1	0.0	DÉBUT	Question reçue ; 5 étapes max, source externe activée
2	5.7	DECISION	**Rechercher dans le corpus** — Aucune preuve collectée, commencer une recherche `search_cases("query": "23-20.161 bail rural", "k": 5)`
3	5.7	TOOL	`search_cases(query='23-20.161 bail rural', k=5)`
4	5.7	OBSERVATION	5 décision(s) trouvée(s) ; meilleure : Cass. Civ. 3e, 2025-03-13, n° 23-20.161 ; preuves ajoutées : C1, C2, C3, C4
5	19.9	DECISION	**Lire une décision** — Pas de décision spécifique trouvée pour l'affaire 23-20.161 `read_case("case_id": "D1")` *garde-fou : la décision citée par son numéro a été trouvée mais pas encore lue*
6	19.9	TOOL	`read_case(case_id='D1', pourvoi='23-20.161')`
7	19.9	OBSERVATION	Cass. Civ. 3e, 2025-03-13, n° 23-20.161 (Rejet) : 4 passage(s) lus Exposé du litige, Moyens du pourvoi, Motivations de la Cour, Dispositif ; preuves ajoutées : C5, C6, C7, C8
8	27.3	DECISION	**Rédiger la réponse** — La question cite un numéro de pourvoi et une affaire précise, il faut donc lire la décision déjà trouvée *garde-fou : décision déjà lue*
9	57.2	GÉNÉRATION	Brouillon citant C7 : *Le bailleur reprochait à l'arrêt d'appel qu'il n'avait pas été entendu ou appelé à la procédure, ce qui violait l'article 14 du code de procédure civile. La Cour de cassation a décidé que ce moyen n'est pas fondé et a rejeté le…*
10	64.5	CHECK	**Preuves suffisantes : oui** ; suite : preuves suffisantes
11	64.5	FINAL	**Réponse vérifiée** — condition d'arrêt : réponse finale vérifiée

Réponse finale (vérifiée)

Le bailleur reprochait à l'arrêt d'appel qu'il n'avait pas été entendu ou appelé à la procédure, ce qui violait l'article 14 du code de procédure civile. La Cour de cassation a décidé que ce moyen n'est pas fondé et a rejeté le pourvoi.

[C7] Corpus — Cass. Civ. 3e, 2025-03-13, n° 23-20.161 (Motivations de la Cour) : *« Réponse de la Cour 6. Le preneur à bail rural, agissant en contestation du congé aux fins de reprise pour exploiter délivré par le bailleur, n'est tenu de mettre en… »*

Mesures : 3 décisions de l'agent, 5 appels LLM, 2 appels d'outils, 3723 tokens, 64.5 s. Chemin : agent → tools → agent → tools → agent → answer → verify → final.

4.3 Scénario 3 — Information insuffisante

Question : Qu'est-ce que la théorie de l'imprévision et la Cour de cassation l'a-t-elle appliquée à un contrat ? La notion est générale et le corpus ne contient pas forcément d'arrêt qui la nomme : le premier retrieval est insuffisant, l'agent doit reformuler ou consulter la source externe, sans présenter Wikipédia comme de la jurisprudence.

#	t (s)	Type	Détail
1	0.0	DÉBUT	Question reçue ; 5 étapes max, source externe activée
2	8.0	DECISION	**Rechercher dans le corpus** — Aucune preuve collectée, commencer par une recherche de cas `search_cases("query": "imprévision et contrat", "k": 5)`
3	8.0	TOOL	`search_cases(query='imprévision et contrat', k=5)`
4	8.1	OBSERVATION	5 décision(s) trouvée(s) ; meilleure : Cass. Civ. 3e, 2019-10-17, n° 18-19.611 ; preuves ajoutées : C1, C2, C3, C4, C5
5	22.8	DECISION	**Rédiger la réponse** — Pas de décision spécifique trouvée sur la théorie de l'imprévision et son application à un contrat *garde-fou : des preuves existent déjà : le vérificateur jugera si elles suffisent*
6	33.7	GÉNÉRATION	Brouillon citant C1, C5 : *La Cour de cassation a appliqué la théorie de l'imprévision à un contrat de travail, en considérant que la rupture du contrat se prescrit par douze mois à compter de la notification de la rupture.*
7	53.8	CHECK	**Preuves suffisantes : non** — échecs : notions clés sourcées, cohérence réponse/passages notion(s) de la question absente(s) des preuves : imprevis, theor ; affirmations non justifiées : La Cour de cassation a appliqué la théorie de l'imprévision à un contrat de travail, en considérant… ; suite : insuffisant nouvelle recherche
8	65.9	DECISION	**Rechercher dans le corpus** — Manque de précision sur l'application de la théorie de l'imprévision aux contrats de travail `search_cases("query": "théorie de l'imprévision et contrat de travail", "k": 5)`
9	65.9	TOOL	`search_cases(query='théorie de l'imprévision et contrat de travail', k=5)`
10	66.0	OBSERVATION	5 décision(s) trouvée(s) ; meilleure : Cass. Soc., 2022-09-21, n° 21-16.821 ; preuves ajoutées : C6, C7, C8, C9, C10
11	85.5	DECISION	**Consulter la source externe** — Manque de précision sur l'application de la théorie de l'imprévision `external_search("query": "Qu'est-ce que la théorie de l'imprévision et la Cour de cassation l'a-t-elle appliquée à un contrat ?")` *garde-fou : recherche identique ou quasi identique à une recherche déjà faite*
12	85.5	TOOL	`external_search(query="Qu'est-ce que la théorie de l'imprévision et la Cour de cassation l'a-t-elle…`
13	86.7	OBSERVATION	API externe : 2 article(s) Théorie de l'imprévision, Théorie de l'imprévision en droit français ; preuves ajoutées : E1, E2
14	105.0	DECISION	**Lire une décision** — Manque de précision sur l'application de la théorie de l'imprévision `read_case("case_id": "D1")` *garde-fou : recherche identique ou quasi identique à une recherche déjà faite*
15	105.0	TOOL	`read_case(case_id='D1', pourvoi='18-19.611')`
16	105.0	OBSERVATION	Cass. Civ. 3e, 2019-10-17, n° 18-19.611 (Cassation) : 5 passage(s) lus Sommaire, Exposé du litige, Moyens du pourvoi, Motivations de la Cour, Dispositif ; preuves ajoutées : C11, C12, C13

#	t (s)	Type	Détail
17	105.0	DECISION	**Limite de 5 étapes atteinte : réponse avec les preuves disponibles.** — *garde-fou : limite d'étapes*
18	143.3	GÉNÉRATION	Brouillon citant C12, C13, C8 : *La Cour de cassation a appliqué la théorie de l'imprévision au contrat de travail, mais la rupture du contrat se prescrit par douze mois Î compter de la notification de la rupture.*
19	167.7	CHECK	**Preuves suffisantes : non** — échecs : cohérence réponse/passages affirmations non justifiées : La Cour de cassation a appliqué la théorie de l'imprévision au contrat de travail, mais la rupture du contrat se prescrit par douze mois Î compter de la notification de… ; suite : insuffisant limite d'étapes atteinte
20	167.7	FINAL	**Réponse non vérifiée** — condition d'arrêt : limite d'étapes atteinte (réponse non vérifiée)

Réponse finale (non vérifiée)

La Cour de cassation a appliqué la théorie de l'imprévision au contrat de travail, mais la rupture du contrat se prescrit par douze mois Î compter de la notification de la rupture.

[C12] Corpus — Cass. Civ. 3e, 2019-10-17, n° 18-19.611 (Moyens du pourvoi) : *« Sur le moyen unique du pourvoi n° 18-19.611 : »*

[C13] Corpus — Cass. Civ. 3e, 2019-10-17, n° 18-19.611 (Dispositif) : *« PAR CES MOTIFS, et sans qu'il y ait lieu de statuer sur le moyen unique du pourvoi n° 18-20.550 : CASSE ET ANNULE, en toutes ses dispositions, l'arrêt rendu le 17 mai… »*

[C8] Corpus — Cass. Soc., 2023-09-27, n° 21-25.973 (Motivations de la Cour) : *« Réponse de la Cour Vu l'article L. 1231-1 du code du travail : 5. Selon ce texte, le contrat de travail à durée indéterminée peut être rompu à l'initiative de… »*

Mesures : 5 décisions de l'agent, 9 appels LLM, 4 appels d'outils, 9130 tokens, 167.7 s. Chemin : agent → tools → agent → answer → verify → agent → tools → agent → tools → agent → tools → agent → answer → verify → final.

5 Comparaison avec le RAG statique du TP2

Le RAG statique exécute, pour la même question, une recherche hybride, prend 5 passages (2 au plus par décision) et génère une réponse citée en un seul appel LLM.

Scénario	Système	Résultat	Appels LLM	Outils	Tokens	Durée (s)
RAG simple	Agent	vérifiée	4	1	4898	85.2
	RAG statique	répond	1	1	1768	15.1
Multi-étapes	Agent	vérifiée	5	2	3723	64.5
	RAG statique	répond	1	1	1359	10.9
Information insuffisante	Agent	non vérifiée	9	4	9130	167.7
	RAG statique	répond	1	1	1619	16.6

Table 4 – Coût et résultat de l'agent et du RAG statique sur les trois scénarios (même modèle, même index).

RAG simple. *RAG statique* : Non, le juge judiciaire ne peut apprécier le caractère réel et sérieux du licenciement d'un salarié protégé autorisé par l'inspecteur du travail, car il ne s'agit pas d'un licenciement économique, mais d'un licenciement protégé qui doit être apprécié par le juge administratif ou le ministre compétent. (sources : aucune)

Multi-étapes. *RAG statique* : Le preneur à bail rural n'est tenu de mettre en cause à l'instance que ce dernier, qui a seul, par cet acte, manifesté sa volonté de rompre le bail. (sources : aucune)

Information insuffisante. *RAG statique* : La Cour de cassation a appliqué la théorie de l'imprévision dans un contrat de travail, en considérant que les liens plus étroits avec un autre pays ne permettent pas dçevrer des dispositions impératives plus favorables. (sources : aucune)

Où l'agent apporte une vraie valeur. Sur le scénario 2, la question vise une affaire précise et deux éléments de la décision (le grief du pourvoi et la solution). Le RAG statique ne répond qu'à moitié : il recopie la règle posée par la Cour, sans le grief ni la solution, et sans citer de passage. L'agent trouve la décision par son numéro, la *lit* zone par zone (moyen, motivations, dispositif) et produit une réponse complète, citée et vérifiée, en 64 s. Sur le scénario 3, les deux systèmes reprennent la même affirmation fausse (« la Cour a appliqué l'imprévision au contrat de travail ») ; mais le RAG statique la présente comme un fait, alors que l'agent relance la recherche, consulte la source externe puis rend sa réponse avec le statut *non vérifiée* et le motif. Sur une question juridique, savoir signaler qu'on ne sait pas vaut presque autant qu'une bonne réponse.

Où le RAG simple est préférable. Pour une question de principe dont la réponse tient dans un sommaire (scénario 1), le RAG statique donne la bonne conclusion en un seul appel LLM, en 15 s contre 85 s pour l'agent (4 appels LLM, environ trois fois plus de tokens). Sur CPU, chaque appel au modèle 3 B coûte 10 à 40 secondes : la latence est le premier prix de l'agentivité. Le RAG statique est aussi plus prévisible (toujours le même chemin) et plus simple à tester. Sa faiblesse est ailleurs : dans nos trois essais, il n'a cité *aucun* passage et a ajouté une justification inventée au scénario 1 (« il ne s'agit pas d'un licenciement économique »), ce qu'aucun contrôle ne détecte dans un pipeline fixe.

6 Analyse

6.1 Ce qui fonctionne

— Le chemin nominal *recherche* → *lecture* → *réponse* → *vérification* est suivi sans étape inutile quand la question est claire.

— Les garde-fous rendent le système robuste aux erreurs d'un petit modèle, et ces corrections sont visibles dans la trace au lieu d'être silencieuses.

— La lecture « par zone » (exposé, moyens, motivations, dispositif) donne au rédacteur exactement les passages qu'un juriste lirait.

— Le vérificateur détecte réellement des erreurs : réponses fondées sur la mauvaise affaire, affirmations absentes des passages, réponses sans citation.

6.2 Échecs observés

— **Boucle de recherche.** Dans les premières versions, le modèle 3 B relançait la même recherche ou relisait l'affaire déjà lue ; un premier garde-fou le redirigeait vers des affaires sans rapport, et la réponse finale portait sur une autre décision. Correction : une affaire déjà lue mène à la réponse, et la sélection des preuves privilégie l'affaire citée par son numéro.

— **Vérification trompée par des preuves hors sujet.** Une réponse sur les « fumures et arrière-fumures » (affaire 23-19.267) a été validée pour une question sur l'affaire 23-20.161 : elle était bien soutenue par les passages cités, mais pas par la bonne affaire. D'où le contrôle « affaire demandée citée ».

— **Faux négatifs du juge LLM.** Le juge 3 B a déclaré « non justifiée » une phrase recopiant presque mot pour mot le moyen du pourvoi, ce qui a déclenché des recherches inutiles jusqu'à la limite d'étapes. Ses objections sont désormais confrontées au contrôle lexical.

— **Vocabulaire.** « Que reprochait le bailleur ? » ne partage aucun mot avec « M. [T] fait grief à l'arrêt » : sans l'enrichissement de la requête par le vocabulaire des arrêts, le passage décisif n'était pas retrouvé.

— **Hallucination validée, puis corrigée.** Dans une version intermédiaire, la réponse du scénario 3 (« la Cour a appliqué l'imprévision au contrat de travail ») a été *vérifiée* : le juge LLM l'avait bien rejetée, mais son objection avait été écartée parce que la plupart des mots de la phrase figuraient dans les preuves. Le mot décisif, « imprévision », n'y figurait pas. D'où le contrôle « notions clés sourcées » : un terme rare de la question (IDF ≥ 6) repris dans la réponse doit apparaître dans les preuves.

— **Le rédacteur ignore la source externe.** Dans la trace finale du scénario 3, l'agent a bien récupéré la définition de Wikipédia, mais le modèle 3 B rédige encore la même affirmation fausse au lieu de s'appuyer sur [E1]. Le vérificateur l'arrête : la réponse sort avec le statut *non vérifiée*. Le système échoue proprement, mais il échoue.

— **Non-déterminisme observé pendant la démo vidéo.** En relançant le scénario 2 en direct, le modèle a renvoyé une action *vide* après la recherche ; le garde-fou « action invalide » a alors choisi de rédiger avant d'avoir lu l'affaire demandée. Le vérificateur a refusé la réponse (« la réponse s'appuie sur une autre affaire que celle demandée »), l'agent a lu la bonne décision et la réponse finale a été vérifiée, mais en 173 s au lieu de 64 s. Correction : la règle « affaire citée par son numéro mais pas encore lue » s'applique désormais avant toute autre, y compris sur une action invalide (test ajouté).

6.3 Améliorations possibles

— Un modèle plus grand ou spécialisé (7 B quantifié, ou GPU) pour le juge et l'agent : la plupart des garde-fous compensent des erreurs de raisonnement du 3 B.

— Un *reranker* (cross-encoder multilingue) après l'index hybride, pour mieux ordonner les passages avant la lecture.

— Une vraie API juridique (Judilibre, Légifrance via PISTE) à la place de Wikipédia, pour citer les textes de loi visés.

— Une décision « règle d'abord, LLM ensuite » : router sans LLM les questions qui contiennent un numéro de pourvoi, et réserver le LLM aux cas ambigus.

— Autoriser une réponse *négative* vérifiable (« aucune décision du corpus consulté n'applique cette notion », appuyée sur la liste des recherches faites), plutôt que d'exiger une décision du corpus citée : c'est la bonne réponse au scénario 3.

Question directrice : de meilleures décisions, ou seulement plus d'appels LLM ? Les deux, selon la question. Sur une question de principe, l'agent ajoute surtout des appels autour du même RAG. Sur une question qui exige de choisir une source (une affaire précise, une notion absente du corpus), il prend de meilleures décisions que le pipeline fixe, *à condition* d'être encadré : avec un modèle de 3 B, la qualité vient autant des garde-fous et du vérificateur en code que du LLM lui-même.

7 Conclusion

Ce TP a transformé le RAG statique du TP2 en un assistant juridique *agentique* : le modèle choisit ses actions, le code exécute les outils, et un vérificateur décide si les preuves suffisent avant de laisser passer la réponse. Les trois scénarios montrent les trois comportements attendus : une seule recherche quand elle suffit, une lecture ciblée quand la question vise une affaire précise, et une relance (nouvelle requête puis source externe) quand le corpus ne répond pas.

Le principal enseignement est que, avec un modèle de 3 B paramètres exécuté sur CPU, la fiabilité ne vient pas du modèle seul : elle vient de l'encadrement en code (garde-fous, contrôles de citations, notions clés, affaire demandée) et de la **transparence** de l'exécution. Quand l'agent échoue, comme au scénario 3, il le signale au lieu de l'affirmer. C'est la propriété qui compte le plus pour un outil juridique.

A Installation et reproduction des résultats

A.1 Prérequis

— Python 3.11 ou plus récent, environ 2 Go d'espace disque libre, 8 Go de RAM (16 Go conseillés) ;
— Ollama installé, avec le modèle `llama3.2:3b` (2 Go) ;
— une connexion Internet pour la première préparation (dataset Hugging Face, modèle d'embeddings) et pour la source externe (Wikipédia).

A.2 Installation et lancement

```
git clone https://github.com/anas-06/TP-LLM.git && cd TP-LLM
pip install -r requirements.txt
ollama pull llama3.2:3b

python -m scripts.prepare_juris --n 2000      # corpus : ~2 000 décisions (~2 min)
python -m scripts.build_index                 # index BM25 + embeddings (20-40 min sur
    CPU)
uvicorn backend.main:app --port 8000          # interface : http://localhost:8000
```

L'onglet *Recherche d'affaires* correspond au TP2, l'onglet *Agent juridique* au TP3 ; le TP1 reste disponible sur `/tp1`.

A.3 Reproduire les expériences de ce rapport

```
python -m scripts.run_scenarios               # 3 scénarios + RAG statique -> docs/traces/

python -m scripts.make_report_tables          # tableaux LaTeX des sections 4 et 5
pytest -q                                     # 27 tests (le LLM est remplacé par un faux)
```

Une trace enregistrée peut être rejouée dans l'interface : `http://localhost:8000/?trace=scenario_s2`.

A.4 Organisation du code

Fichier ou dossier	Rôle
`backend/juris/corpus.py`	chargement des décisions, zones, découpage en passages
`backend/juris/index.py`	index hybride BM25 + embeddings, fusion RRF
`backend/juris/rag.py`	recherche, résumé, questions-réponses, RAG statique (TP2)
`backend/agent/tools.py`	les trois outils de l'agent
`backend/agent/graph.py`	graphe LangGraph : agent, outils, réponse, vérificateur, final
`backend/agent/runner.py`	exécution en arrière-plan, trace en direct, mémoire, sauvegarde
`backend/juris_api.py`	routes de l'API (`/api/juris/*`, `/api/agent/*`)
`frontend/app/`	interface web (HTML, CSS, JavaScript sans dépendance)
`scripts/`	préparation des données, index, scénarios, tableaux et captures du rapport
`docs/traces/`	traces des trois scénarios (JSON et Markdown)
`tests/`	tests du TP1 et de l'agent

Code source : `https://github.com/anas-06/TP-LLM`

B Glossaire

Terme	Définition
RAG	*Retrieval-Augmented Generation* : le modèle répond à partir de passages retrouvés dans un corpus plutôt que de sa seule mémoire.
Agentic RAG	RAG dans lequel le modèle décide lui-même quand chercher, quoi lire et quand répondre, au lieu de suivre une chaîne fixe.
BM25	score de recherche lexicale fondé sur la fréquence des mots dans le passage et leur rareté dans le corpus.
Embedding	vecteur qui représente le sens d'un texte ; deux textes proches ont des vecteurs proches (recherche dense).
RRF	*Reciprocal Rank Fusion* : fusion de plusieurs classements par la somme de $1/(k + \text{rang})$.
IDF	*Inverse Document Frequency* : mesure de la rareté d'un mot dans le corpus ; un IDF élevé signale un terme précis.
Garde-fou	règle écrite en code qui corrige une décision invalide du modèle (action inconnue, recherche répétée…).
Juge LLM	appel au modèle chargé de vérifier qu'une réponse est justifiée par les passages fournis.
SSE	*Server-Sent Events* : flux HTTP par lequel le serveur envoie la trace au navigateur au fil de l'exécution.
Sommaire	résumé officiel de la règle de droit posée par un arrêt publié au Bulletin.
Dispositif	partie finale d'un arrêt qui énonce la décision (« rejette », « casse et annule »).
Moyen	argument juridique présenté par l'auteur du pourvoi (« fait grief à l'arrêt de… »).